

Proyecto Final

Chatbot para

Técnicos

Felix Omar Dominguez Inestroza - 12141043
Samuel Andres Rocha Castro - 21941333



Índice

Planteamiento del problema

Objetivos

Trabajo relacionado

Modelos de ML

Frameworks de desarrollo

Arquitectura

Demostración

Experimentación y optimización


Métricas

Fortalezas y limitaciones

Planteamiento del Problema

El 80% de los técnicos de campos se suelen tardar entre 30 minutos a 2 horas en solo buscar la información necesaria para hacer su trabajo, además recalcan el tiempo que se pierde en buscar dentro de la documentación misma. También el 95% de los casos los técnicos tuvieron que agendar una segunda visita a su cliente simplemente porque no contaban con la información necesaria. Por esto podemos ver los diferentes problemas a los que se afrontan los técnicos los cuales generan perdida de tiempo, errores de diagnostico y retrasos a la atención al cliente.

(Muffat, 2023)



Descripcion de la Solucion

Para resolver la problemática planteada desarrollaremos un chatbot conversacional basado en un modelo LLM respaldada por información de un base de datos vectorial de donde sacara la información para brindar las respuestas necesarias. El chatbot estará diseñado para brindar respuestas sobre problemas y cuestiones técnicas de productos electrónicos, industriales o cualquier tipo de producto que tenga instrucciones para su uso y posibles problemas que se podrían resolver con el uso de un manual.

Objetivo General

Desarrollar un sistema de RAG orientado a técnicos de campo en el area de dispositivos de refrigeracion, integrado en un chatbot para facilitar la consulta rápida y precisa de manuales técnicos a través de interacciones en lenguaje natural.

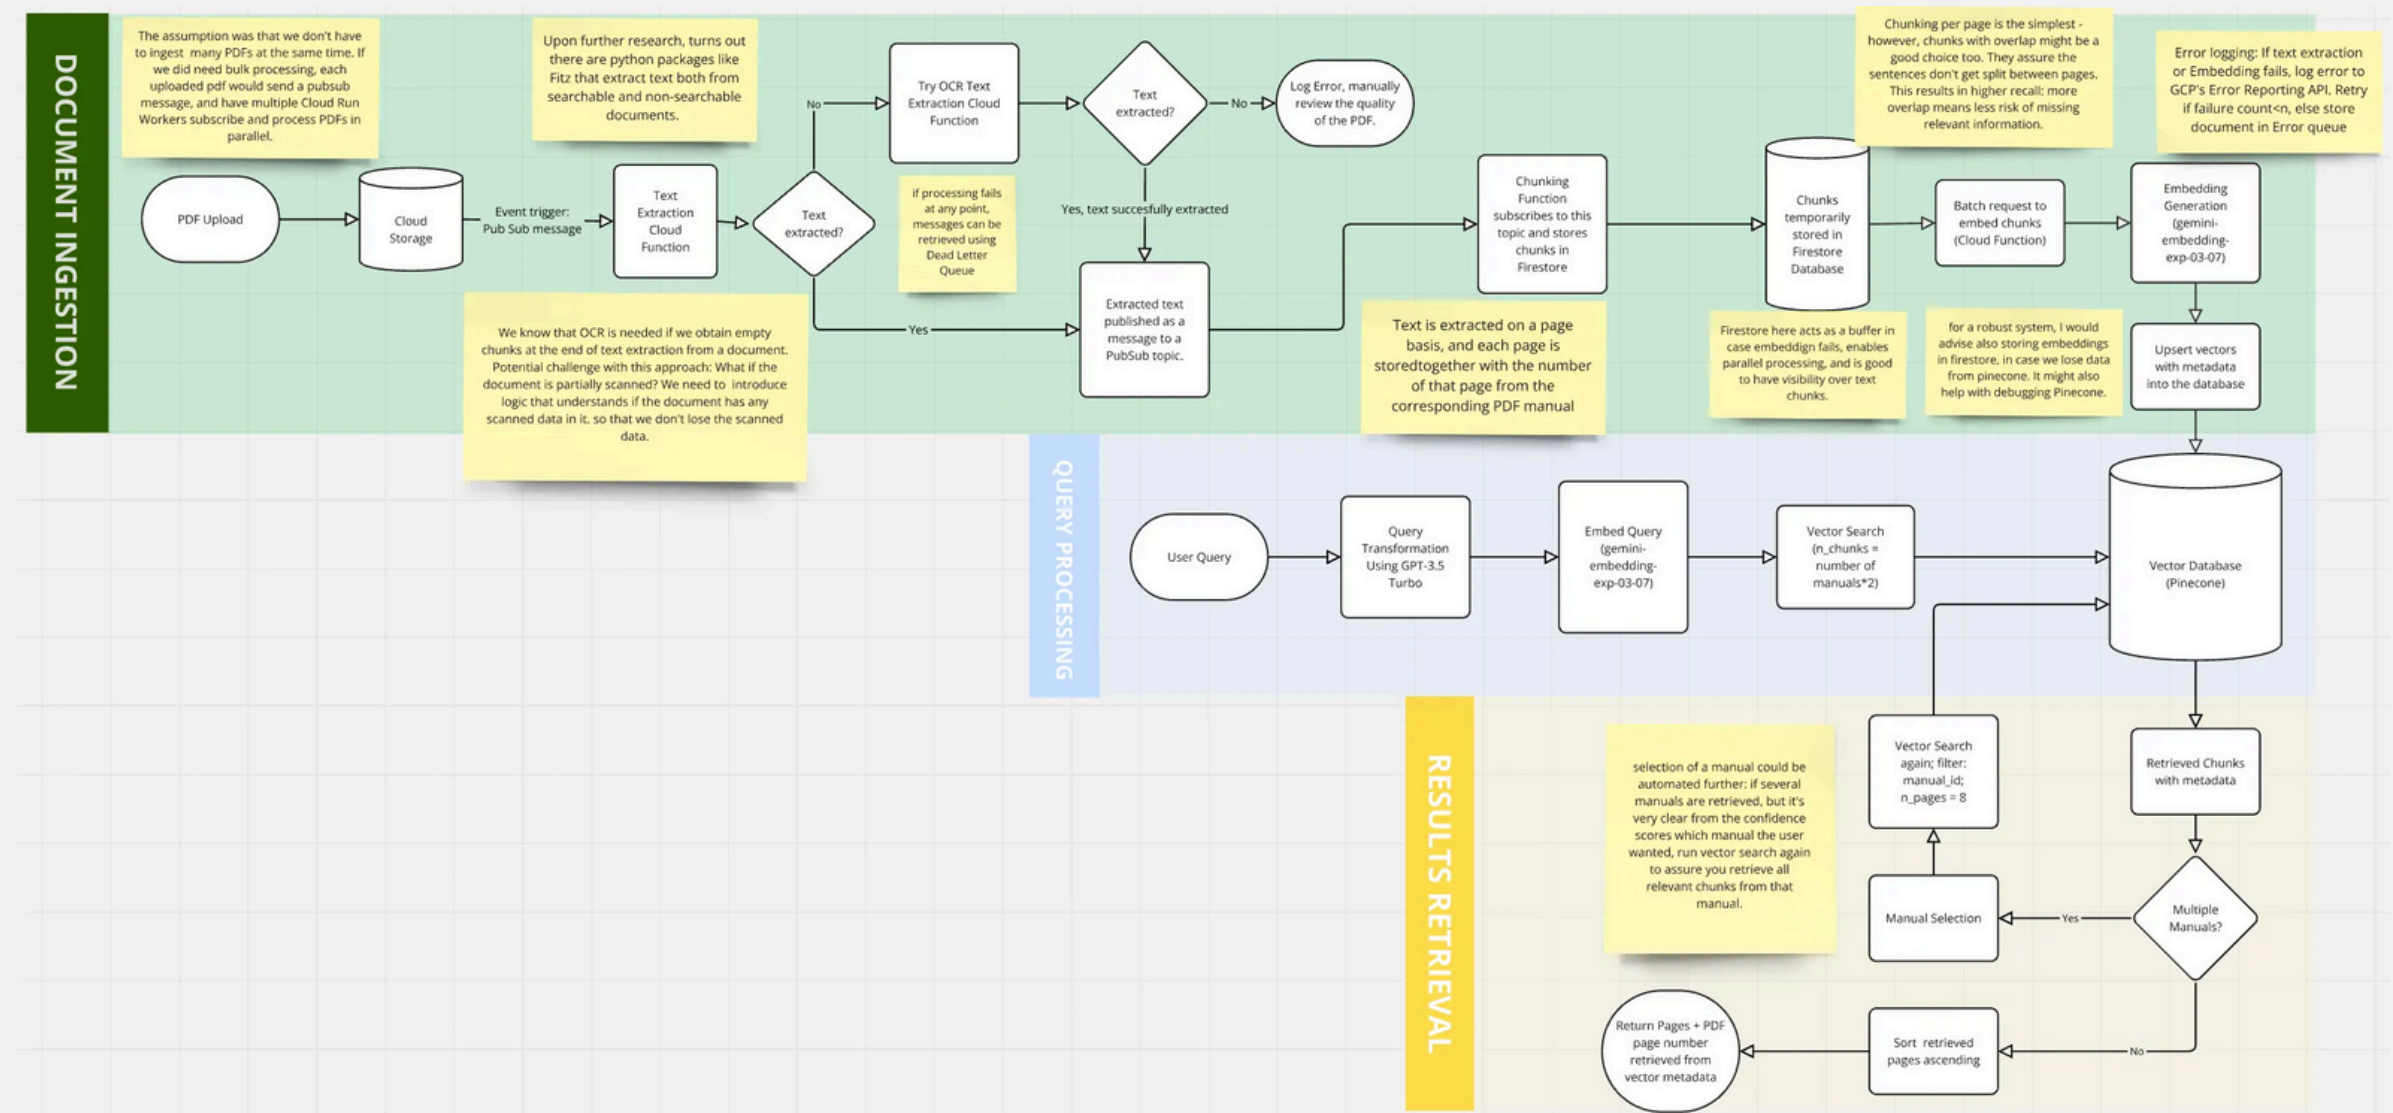
Objetivos Específicos

1. Recopilar, preparar y preprocesar manuales técnicos de dispositivos en el area de refrigeracion de diferentes marcas para construir una base de conocimientos.
2. Diseñar y desarrollar el pipeline RAG completo utilizando LangChain.
3. Desarrollar un chatbot que sirva de interfaz para los técnicos, conectando la logica del pipeline con una interfaz de usuario accesible.

Trabajo relacionado

Manuales de motores para maquinaria pesada

Un chatbot RAG especializado en brindar instrucciones de manuales de maquinaria pesada a los técnicos directamente de los manuales. (Ilic, 2025)





Etapas de RAG

Modelos de ML

Etapas de Ingesta

Sentence Transformers con
Paraphrase Multilingual
MPNET para crear los
embeddings.

Etapas de recuperación

Qwen 2.5 para reformular la
consulta y extraer los modelos
de equipo de la consulta.
BGE reranker para re ordenar
los resultados.

Etapas de generación

GROQ
LLAMA-4-SCOUT



Frameworks de desarrollo

LangChain y React

LangChain

- ChromaDB
- Ollama
- SentenceTransformer
- PyMuPDFLoader
- Text Splitter

React

- Interfaz de usuario de chat en tiempo real
- Groq LLM
- Llama-4-scout


LLM: Llama-4-scout-17b-16e-instruct y Groq

Groq:

- Facilita cargas de modelo que no serian posibles con varios cpus
- Tiene una version gratis mas que capaz para el proyecto
- Muy facil de utilizar

Llama-4-scout:

- Respuestas de alta calidad
- Limites de tokens aceptables para realizacion de pruebas dentro de la version gratis
- Modelo anterior: llama-3.1-8b-instant



UI: React

1. Experiencia anterior:

- Es el unico framework para desarrollo web con el cual tengo experiencia

2. Opciones:

- Este brinda varias opciones para brindar ambos una apariencia con mucho estilo y ademas ayuda en la parte de la implementacion de la logica.



Backend: Next.js




1. Next.js como route handler:


- Next.js App Router, tiene su propio framework de react ya integrado

2. Otros elementos:

- Runtime de Node.js
- Streaming SSE
- Traducción para el RAG con: [@vitalets/google-translate-api](#)
- Deteccion sencilla de idioma
- Streaming SSE
- Llamada al servidor del RAG
- Uso de api de Groq para llamar a llama-4-scout-17b-16e-instruct



Arquitectura



Demostracion



Historial

Mi freezer estan congelando mas de lo qu

¿Qué refrigerante utiliza el aire acondicionado?

Nuevo chat

Manually

Mi freezer estan congelando mas de lo que deberia

Diagnóstico

El problema de congelamiento excesivo en tu freezer puede deberse a varias causas. Según los documentos disponibles, algunos posibles motivos incluyen:

Configuración incorrecta de temperatura: Es posible que la temperatura configurada sea demasiado baja.

Problemas con el termostato: El termostato podría estar fallando o estar configurado incorrectamente.

Acumulación de hielo en la unidad exterior (solo para modelos de bomba de calor): Esto puede ocurrir durante el funcionamiento en modo de calefacción a bajas temperaturas exteriores.

"Durante la calefacción a bajas temperaturas exteriores, es posible que se forme escarcha en el intercambiador de calor de la unidad exterior. Esta acumulación de escarcha restringirá el flujo de aire a través del intercambiador de calor y, por lo tanto, el rendimiento del acondicionador de aire se reducirá gradualmente."

Escribe tu pregunta técnica...

Enviar

Llama 3.1 - vía Groq - Streaming activado

Experimentación

Modelo de embeddings


Modelos basados en imágenes

ColPali es un modelo que permite la recuperación de documentos en base a imágenes. Se considera cada página del documento como una imagen. No se extrae el texto.

Modelos basados en textos


Se experimenta con modelos para balancear tamaño, calidad y soporte de idiomas.

- All MiniLM L6
- Distiluse Base Multilingual
- Paraphrase multilingual mpnet



Experimentación


ColPali



- Ventajas
 - Mejor recuperación en base a diagramas, circuitos, tablas.
- Desventajas
 - Recuperación en formato de imágenes
 - Dependencia de LLM multimodal


Experimentación

Paraphrase Multilingual MPNET



- Ventajas
 - Soporte de multiples idiomas como el español y el inglés.
 - Resultados en texto
 - Metadatos en cada chunk
- Desventajas
 - Mayor tamaño en comparación con otros modelos de texto
 - Baja o nula comprensión de diagramas.
 - Requiere mas procesamiento de texto y técnicas como OCR.

Chunking for RAG



Experimentación

Optimización de Ingesta

Chunking de documentos

Se experimenta con diferentes técnicas de chunking para obtener los mejores resultados.

- Chunks por página
- Chunks por secciones
- Chunk fijo + overlap

Extracción de modelos

Mediante Qwen 2.5 se extrae el modelo de las primeras páginas de cada documento. Esto permite agregar a los metadatos de cada chunk para su posterior filtrado por modelos de equipos.

Experimentación

Optimización de Recuperación

Detección de modelo y filtro

Para mejorar la precisión de las respuestas, Qwen 2.5 extrae el modelo de la consulta del usuario y aplica un filtro para mostrar solo los resultados que apliquen a ese modelo.

Optimización de la consulta


Qwen 2.5 optimiza la consulta del usuario, corrigiendo potenciales errores y colocando términos técnicos.


Reranking de los resultados

Usando el reranker BGE se ordenan los resultados según un orden de relevancia.

Vector Search

Reranking






Experimentación

Querys hacia el LLM y RAG

- Dos formatos fijos
- Que sea conciso, pero no demasiado
- Priorizar la información de RAG cuando este aplique
- Tener dos querys, (español e inglés)

RAG

- Pasar querys en español a inglés para el RAG



Experimentación

Elección de Modelo

- Originalmente se probó con llama-3.1-8b-instant
- Finalmente, se decidió Llama-4-scout-17b-16e-instruct

Decisión:

- Mucho más coherente
- Límites de tokens aceptables
- Mas lento, pero no tanto
- Incorporación mejor de contexto

Métricas de rendimiento

Retrieval MRR

Mean Reciprocal Rank (MRR) se calcula como

$$MRR = \frac{1}{i}$$

Donde i es el indice del primer resultado relevante.

	Sin optimizar	Ranking	Optimización	Opt + Ranking
Query 1	1.0	1.0	1.0	1.0
Query 2	0.250	0.250	0.25	1.0
Query 3	0.333	0.333	0.0	0.0
Query 4	0.200	0.200	0.25	1.0
Query 5	0.500	0.500	1.0	1.0
Score	45%	45%	50%	80%

Rendimiento Groq

REQUEST TIME	MODEL	API KEY	CODE	TTFT	LATENCY	INPUT TOKENS	OUTPUT TOKENS	AUDIO SECONDS	REQUEST ID
3/12/2025, 15:05:33	meta-llama/llama-4-scout-17b-16e-instruct	ProyectoAM1 ⓘ	200	0.090	1.267	1445	461	-	req_0...bs8r
3/12/2025, 14:09:41	meta-llama/llama-4-scout-17b-16e-instruct	ProyectoAM1 ⓘ	200	0.234	1.537	2845	493	-	req_0...mv1b
3/12/2025, 14:00:06	meta-llama/llama-4-scout-17b-16e-instruct	ProyectoAM1 ⓘ	200	1.216	2.055	1871	360	-	req_0...qc8d
3/12/2025, 13:27:02	meta-llama/llama-4-scout-17b-16e-instruct	ProyectoAM1 ⓘ	200	0.158	1.213	1830	393	-	req_0...7b6n
3/12/2025, 13:25:53	meta-llama/llama-4-scout-17b-16e-instruct	ProyectoAM1 ⓘ	200	0.321	1.403	1601	438	-	req_0...0m44
3/12/2025, 13:20:04	meta-llama/llama-4-scout-17b-16e-instruct	ProyectoAM1 ⓘ	200	0.401	1.010	1724	235	-	req_0...nwma
3/12/2025, 13:19:14	meta-llama/llama-4-scout-17b-16e-instruct	ProyectoAM1 ⓘ	200	0.134	0.945	1569	294	-	req_0...s4rz
3/12/2025, 13:17:17	meta-llama/llama-4-scout-17b-16e-instruct	ProyectoAM1 ⓘ	200	0.127	0.401	1498	100	-	req_0...ckzb
3/12/2025, 13:14:27	meta-llama/llama-4-scout-17b-16e-instruct	ProyectoAM1 ⓘ	200	0.098	0.432	1497	121	-	req_0...zacv
3/12/2025, 13:13:58	meta-llama/llama-4-scout-17b-16e-instruct	ProyectoAM1 ⓘ	200	0.110	0.270	1630	69	-	req_0...rx5t

Rendimiento Groq

2/12/2025, 20:57:18 llama-3.1-8b-instant	ProyectoAM1 ⓘ	200	0.323	0.712	1340	297	-	req_0...3d20
2/12/2025, 20:52:46 llama-3.1-8b-instant	ProyectoAM1 ⓘ	200	0.112	0.517	1340	306	-	req_0...ybqn
2/12/2025, 20:52:28 llama-3.1-8b-instant	ProyectoAM1 ⓘ	200	0.295	0.939	1560	388	-	req_0...fx7w
2/12/2025, 20:50:09 llama-3.1-8b-instant	ProyectoAM1 ⓘ	200	0.531	0.956	1340	319	-	req_0...228z
2/12/2025, 20:49:45 llama-3.1-8b-instant	ProyectoAM1 ⓘ	200	0.438	0.854	1560	274	-	req_0...hgwf
2/12/2025, 20:48:43 llama-3.1-8b-instant	ProyectoAM1 ⓘ	200	0.369	0.774	1560	294	-	req_0...smma
2/12/2025, 20:48:24 llama-3.1-8b-instant	ProyectoAM1 ⓘ	200	0.202	0.669	1340	343	-	req_0...aq0q
2/12/2025, 20:46:23 llama-3.1-8b-instant	ProyectoAM1 ⓘ	200	0.334	0.879	1340	364	-	req_0...s4st
2/12/2025, 20:41:32 llama-3.1-8b-instant	ProyectoAM1 ⓘ	200	0.200	0.662	1340	343	-	req_0...tt81
2/12/2025, 20:41:16 llama-3.1-8b-instant	ProyectoAM1 ⓘ	200	0.160	0.665	1340	356	-	req_0...bqf3

Rendimiento Groq

Llama 4 Scout 17B 16E 	
meta-llama/llama-4-scout-17b-16e-instruct 	
LIMITS	Requests 30 / minute 1K / day Tokens 30K / minute 500K / day
RELEASE STAGE	Preview
RELEASED	April 5, 2025

Llama 3.1 8B 	
llama-3.1-8b-instant 	
LIMITS	Requests 30 / minute 14.4K / day Tokens 6K / minute 500K / day
RELEASE STAGE	Production
RELEASED	September 3, 2023

Fortalezas

Bajo costo computacional

UTILIZAR GROQ PERMITE USAR MODELOS MÁS POTENTES

Buena velocidad

AUNQUE NO INSTANTANEO BRINDA RESPUESTAS MUY RAPIDO

Informacion Adicional

EL LLM BRINDA INFORMACION ADICIONAL BASTANTE BUENA

Consistencia

LA RECUPERACION DE DOCUMENTOS PERMITE GENERAR RESPUESTAS CONSISTENTES.

Costo Computacional

USAR UN MODELO OPEN SOURCE, QUE ESTE OPTIMIZADO

Tamaño de Documentos

REALIZAR FRAGMENTACION EN LOS DATOS

Calidad de Datos

APLICAR LIMPIEZA SEMANTICA Y USAR OCR

Escalabilidad

AGREGAR MÁS DOCUMENTOS PERMITE INDEXAR RAPIDAMENTE SIN REENTRENAR EL MODELO

Limitaciones

Idioma

PARA AMBOS EL RAG Y EL LLM EL IDIOMA ES UN PROBLEMA

Escalabilidad

YA EN UN AMBIENTE DE PRODUCCION GROQ NO SERIA IDEAL

Modelo

EL MODELO TIENDE A AGREGAR COSAS QUE TALVEZ NO APLICAN

Imágenes

LOS DIAGRAMAS Y OTROS ELEMENTOS VISUALES NO SE INDEXAN BIEN

Costo Computacional

USAR UN MODELO OPEN SOURCE, QUE ESTE OPTIMIZADO

Tamaño de Documentos

REALIZAR FRAGMENTACION EN LOS DATOS

Calidad de Datos

APLICAR LIMPIEZA SEMANTICA Y USAR OCR

Chunks

LA CALIDAD Y TAMAÑO DE LOS CHUNKS AFECTA A LA RECUPERACIÓN

Conclusiones

- Se logro el desarrollo de un chatbot el cual es capaz de brindar respuestas rápidas, precisas y respaldadas de un sistema de RAG.
- Se pudo crear una base de conocimientos a base de varios manuales de usuario de dispositivos de refrigeración.
- Con langchain y varias otras tecnologías utilizadas se logró crear un sistema de RAG, bastante efectivo a la hora de encontrar contexto
- Con React se logró desarrollar una interfaz amigable y muy fácil de usar que utilizara el pipeline de RAG, para brindar respuestas basadas en contexto y con ayuda de Groq para respuestas más rápidas y coherentes

Recomendaciones

- Buscar otro modelo o método para que el idioma del prompt no afecte a la respuesta del Llm e igual en el RAG
- Se podría implementar con modelos ya mucho más potentes e incluso la posibilidad de buscar en el internet por manuales
- Brindar al rag muchos más manuales para que tenga una mayor base de conocimiento y basarse mucho más en ella.
- Utilizar un modelo de ingesta y recuperación basado en imágenes, como ColPali para diagramas, ilustraciones y otro contenido visual en las respuestas.
- Este proyecto podría aplicar para prácticamente cualquier tipo de producto que tenga una manual y dentro de este halla información sobre reparaciones, instalaciones, parte y más. Como teléfonos, televisiones, computadoras, lavadoras, consolas, entre otros

Bibliografia

Amazon. (2024). What is RAG? - Retrieval-Augmented Generation Explained - AWS. Amazon Web Services, Inc. <https://aws.amazon.com/what-is/retrieval-augmented-generation/>

Belcic, I., & Stryker, C. (2024, December 28). Llamaindex vs Langchain: What's the difference? Ibm.com. <https://www.ibm.com/think/topics/llamaindex-vs-langchain>

Greennode. (2025). 5 Best Embedding Models for RAG: How to Choose the Right One. Greennode.ai. <https://greennode.ai/blog/best-embedding-models-for-rag>

Prieto, R. P. (2025, August 4). Automotive Document Intelligence with MongoDB Atlas Search. MongoDB. <https://www.mongodb.com/company/blog/innovation/automotive-document-intelligence-mongodb-atlas-search>

Shin, M., Song, J., Kim, M.-G., Yu, H. W., Choe, E. K., & Chai, Y. J. (2025). Thyro-GenAI: A Chatbot Using Retrieval-Augmented Generative Models for Personalized Thyroid Disease Management. Journal of Clinical Medicine, 14(7), 2450. <https://doi.org/10.3390/jcm14072450>

Muffat, A.-S. (17 de Abril de 2023). How Tech Doc Fails Service Technicians: A Webinar Recap. Obtenido de Fluid Topics: <https://www.fluidtopics.com/blog/field-service/how-tech-doc-fails-service-technicians/>



**Gracias por su
Atencion**

